高级机器学习课程作业1：从零预训练一个 0.2B Transformer 语言模型，并调整训练配置研究 Scaling Law

同学们好，本课程的作业1，要求同学们基于提供的数据集，从零开始写代码，预训练一个 0.2B 参数量的 Transformer 语言模型，并尝试不同的模型尺寸和不同的训练数据量，研究 Scaling Law。

目录

1. 学习目标
2. 作业任务
   - Part 1 训练数据与分词器
   - Part 2 从零实现模型架构
   - Part 3 训练 0.2B 主模型
   - Part 4 Scaling Law 实验与分析
3. 提交材料、评分标准与注意事项
4. 参考资料

1. 学习目标

完成本作业后，你应当能够：

1. 理解 tokenizer 如何把文本变成 token，并能自己实现 BPE 分词。
2. 实现一个现代 decoder-only Transformer 的各个部件，包括多头注意力、因果掩码、位置编码、归一化与残差连接、前馈层。
3. 实现并调通一个预训练循环，涵盖训练数据的打包、优化器的选择与学习率的调试、checkpoint 的保存与验证评测。
4. 设计并执行一组拟合 Scaling Law 的实验，在不同模型尺寸、不同训练数据量上刻画 compute-optimal 包络，用小模型外推预测大模型的 loss。

2. 作业任务

课程会提供两个训练数据集：小数据集 TinyStories 约 1B tokens，大数据集 FineWeb-Edu `sample-10BT` 约 10B tokens，以及一个参考的 tokenizer：https://huggingface.co/flexitok/bpe_fw_edu_16000（在 FineWeb-Edu 上训练的 16k BPE 词表）。

你需要自己实现模型架构和训练循环，可以使用的库包括 PyTorch、NumPy、`datasets`、`tokenizers`、`tiktoken`、`wandb`、`matplotlib` 和 `scipy` 等。请不要直接使用 HuggingFace 的 `GPT2Model`、`LlamaModel`、`Trainer` 或 nanoGPT 这类现成的模型与训练器。

Part 1 — 训练数据与分词器

语言模型不能直接读文本，需要先把文本切成一个个 token。如果按单词切，词表会很大且容易遇到没见过的词；如果按字符或字节切，序列又会变得很长，训练和推理都更慢。BPE（byte-pair encoding）在两者之间取折中：它从字节级的基础词表出发，统计语料里相邻符号对的出现频率，每次把最频繁的一对合并成一个新符号并记入词表，重复这个过程直到词表达到目标大小，最终得到一份词表和一组有序的合并规则。常见的词和词根会被合并成单个 token，生僻串则退回到更短的片段，于是既不会有未登录词，序列长度也比按字节切短得多。编码时按合并规则依次合并，就把文本切成 token 序列；解码时反查词表拼回文本。

本部分需要完成两件事：

1. 用 BPE 算法在数据集上构建出一个分词器和词表。
2. 使用课程给定的参考词表对训练集进行编码。

实现可以参考 BPE 的原始论文 [1] 和 Karpathy 的 minbpe [2]。

两个数据集的信息如下。

角色	数据集	HF id	规模（tokens）	特点
小	TinyStories	`roneneldar/TinyStories`	~1B	合成儿童故事，词汇简单、强局部连贯 [3]
大	FineWeb-Edu `sample-10BT`	`HuggingFaceFW/fineweb-edu`	~10B	教育向过滤的英文网页，质量较高 [4]

Part 2 — 从零实现模型架构

本部分要求实现 decoder-only GPT 中的以下模块：token embedding 与位置编码、多头自注意力及其因果掩码、前馈层、归一化与残差连接、把隐状态映射回词表的输出头，以及用于生成文本的自回归采样。可以参考 Transformer 的原始论文 [5]、GPT-2 [6] 和 Karpathy 的 nanoGPT [2]，也可以参考课程课件。

下面是 0.2B 主模型的参考配置。

项	值
d_model	1024
n_layers	16
n_heads	16
head_dim	64
d_ff	4096
context length	1024
vocab size	16000
非嵌入参数量	约 201M
总参数量	约 218M

Part 3 — 训练 0.2B 主模型

本部分要完成的任务是写出并调通训练模型的管线，并实际进行训练与评测。

训练模型时，训练数据可以选择小数据集 TinyStories 或大数据集 FineWeb-Edu；想挑战的同学也可以自己收集数据，使用其他数据集与其他分词器。最终需要产出 train 与 val 的 loss 曲线、最终的 checkpoint、若干生成样例，以及下面几个评测指标的结果。

训练配方可以参考：优化器用 AdamW，$\beta_1 = 0.9$，$\beta_2 = 0.95$，weight decay 取 0.1；学习率先线性 warmup 再按 cosine 衰减，warmup 占总步数的 1% 到 2%，主模型的学习率峰值取 3e-4 到 6e-4，最终衰减到峰值的 10%；梯度裁剪取 1.0；主模型的有效 batch 取 0.25M 到 0.5M tokens；并定期在验证集上评估、保存最优的 checkpoint。

评测使用下面三个指标。

交叉熵损失（cross-entropy loss），即模型在验证集上每个 token 的平均负对数似然：

$$L = -\frac{1}{T}\sum_{t=1}^{T} \log p(x_t \mid x_{<t})$$

困惑度（perplexity），即交叉熵的指数，可以理解为模型在每一步平均要在多少个候选之间犹豫，越小越好：

$$\mathrm{PPL} = \exp(L)$$

每字节比特数（bits-per-byte），把损失折算到原始文本的字节上，因此不受词表与分词方式影响，在跨数据集或跨分词器比较时使用：

$$\mathrm{BPB} = \frac{L}{\ln 2} \cdot \frac{N_{\text{tokens}}}{N_{\text{bytes}}}$$

其中 N_{tokens} 与 N_{bytes} 分别是验证集的 token 数与 UTF-8 字节数。请跟踪这些指标随训练的变化并报告最终值。loss 平滑下降、生成的文本局部连贯、训练不发散，就说明训练是正常的，具体数值与数据集和分词器有关，不必追求某个固定值。

Part 4 — Scaling Law 实验与分析

本部分是作业中重要的部分，要求自己设计并执行一组实验，以拟合并分析 Scaling Law。由于训练算力约为 $C = 6ND$，算力固定时模型规模 N 与训练数据量 D 此消彼长，你需要考察在小尺寸模型上实验时，loss 如何随两者的分配而变化，拟合出幂律曲线，再外推出更大尺寸模型在两者如何分配时 loss 最好，以及此时的 loss 是多少。

这里给出两条探索路径，任选一条即可，也欢迎都做。

1. 选择比 0.2B 更小的若干尺寸做实验，拟合后外推出 0.2B 模型的 loss，再与 Part 3 的实测结果比较，看看外推的效果如何。这条路径可以选择一些参数量极小的模型做实验，观察 Scaling Law 在那个尺度上是否依然成立；如果出现偏离，分析偏离的原因。
2. 选择与 0.2B 尺寸接近或更大的若干模型做实验，拟合后外推出比 0.2B 大得多的模型的 loss，并讨论这样外推的可信程度。

实验要记录和分析以下四点：

1. 记录每个 run 的 loss 随训练 tokens 与训练算力 C 的变化。
2. 无论选择哪条路径，都需要拟合出模型损失与模型参数量的曲线 $L(N) = E + A/N^{\alpha_N}$ 并画出 compute-optimal 包络 $L(C) \propto C^{-\alpha_C}$，报告拟合出的指数与系数。
3. 按所选路径做外推：第一条路径外推到 0.2B，与 Part 3 的实测结果比较，报告误差并分析原因；第二条路径外推到更大的模型，给出预测的结果，并查阅公开资料讨论其可信程度。
4. 分析拟合的 α_N 与 α_C 和 Kaplan [7]、Chinchilla [8] 报告值的差异；若偏离，分析可能的原因是什么。

同学们可以选做另外维度的实验：比如固定几个模型尺寸，使用不同的训练数据量训练，观察模型的 loss 随数据量的变化；比如直接进行若干实验，对所有实验数据进行参数化拟合，计算完整的损失函数曲面。

3. 提交材料、评分标准与注意事项

提交材料

请打包提交作业使用的代码仓库、最终 checkpoint 以及一份详细的 PDF 报告。代码部分要包含自己实现的 BPE、模型架构以及训练代码。提交的报告请按作业的四个部分组织（报告需控制在 12 页以内，只讲关键结论，不需要赘述）：

- Part 1：讲解自己实现的 BPE 代码、构建出的分词器与词表细节，并用截图方式展示自己运行分词器编码训练集的过程。
- Part 2：记录并分析自己实现的模型架构。
- Part 3：记录训练配置，展示训练过程和评测过程（包括训练集和验证集的 loss 曲线、评测指标的变化曲线、训练截图）以及若干生成样例。
- Part 4：明确自己选择的实验路径，展示实验的设计思路和具体配置、每个 run 的 loss 曲线与训练记录、拟合出的曲线图与指数系数、外推结果，并分析与 Chinchilla 等经典结论的差异。

评分标准

评分合计 100 分。

任务	分值	要点
Part 1 训练数据与分词器	10	实现 BPE 并验证，用参考词表编码数据集，划分 train 与 val 集
Part 2 模型架构	30	实现注意力、因果掩码、残差连接等 Transformer 语言模型的重要部件
Part 3 训练与评测	10	调通训练管线，曲线健康，能生成局部连贯的文本，三个指标与训练记录完整
Part 4 Scaling Law	30	实验组设计合理，有合理的 $L(N)$ 拟合曲线、compute-optimal 包络和外推结果，对结果的分析以及与 Kaplan、Chinchilla 的对比分析恰当
报告	20	报告内容完整，图表清晰，对作业过程中遇到的困难和异常现象有总结和分析

注意事项

1. 本作业为个人独立作业，但算力按团队配置，周期为 3 周。请同学们合理规划好 GPU 的使用，按时完成作业。
2. 允许使用 AI 工具辅助编写代码，但需要能够解释自己提交的每一部分实现，并在报告中说明 AI 的使用范围。
3. 关于学术诚信，你可以阅读 nanoGPT [2]、CS336 [9]、HuggingFace 文档等公开资料借鉴思路，也可以和同学讨论思路；但不要提交他人或现成仓库的模型与训练器代码，不要与他人共享代码。如果有借鉴和参考，请在报告中列出你的参考资料。

4. 参考资料

1. Sennrich, R., Haddow, B., Birch, A. *Neural Machine Translation of Rare Words with Subword Units*. ACL, 2016. arXiv:1508.07909

2. Karpathy, A. *nanoGPT*, *build-nanogpt*, *minbpe*. GitHub repositories. https://github.com/karpathy
3. Eldan, R., Li, Y. *TinyStories: How Small Can Language Models Be and Still Speak Coherent English?* 2023. arXiv:2305.07759
4. Penedo, G. et al. *The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale*. NeurIPS, 2024. arXiv:2406.17557
5. Vaswani, A. et al. *Attention Is All You Need*. NeurIPS, 2017. arXiv:1706.03762
6. Radford, A. et al. *Language Models are Unsupervised Multitask Learners*. OpenAI Technical Report, 2019.
7. Kaplan, J. et al. *Scaling Laws for Neural Language Models*. 2020. arXiv:2001.08361
8. Hoffmann, J. et al. *Training Compute-Optimal Large Language Models*. NeurIPS, 2022. arXiv:2203.15556
9. Stanford CS336. *Language Modeling from Scratch*. Course materials. https://stanford-cs336.github.io